

ORCA：基于跨资产相关性网络谱特征的市场 涨跌检测与交易策略

——学海拾珠系列之二百八十一

报告日期：2026-08-12

主要观点：

本篇是学海拾珠系列第二百八十一篇，文章提出 ORCA 框架，融合跨资产相关性矩阵的谱特征与传统价格指标，通过随机森林预测十天前瞻窗口的上涨与崩盘概率。

分析师：骆昱杉

执业证书号：S0010522110001

邮箱：luoyushan@hazq.com

分析师：严佳炜

执业证书号：S0010520070001

邮箱：yanjw@hazq.com

相关报告

- 《月内动量周期——“学海拾珠”系列之二百八十》
- 《基于 LPPLS 模型的美股七巨头泡沫与系统性风险研究——学海拾珠系列之二百七十九》
- 《使用机器学习分析顶尖基金的持仓——“学海拾珠”系列之二百七十八》
- 《HANET：基于层次化混合频率注意力模型的宏观感知时间序列预测——“学海拾珠”系列之二百七十七》
- 《基金财务报表信息能预测未来业绩吗？——“学海拾珠”系列之二百七十六》
- 《基于大语言模型的语义引导搜索 Alpha 因子——“学海拾珠”系列之二百七十五》

● 危机检测的结构性视角

金融危机前，弱相关资产同步运动，相关性矩阵的谱属性在波动率飙升前即已转变。传统 GARCH 等模型本质上是反应性的，而实务系统将高维依赖结构简化为 VIX 等单一标量，丢弃了关键的拓扑预警信息。ORCA 旨在填补这一空白。

● 研究方法：谱-传统特征融合框架

ORCA 在 24 只多元化 ETF 上构建三个并行相关性估计器（60 天、120 天、指数加权），提取 127 个谱特征（吸收比、特征值熵、谱差距、图拓扑等），与 79 个传统价格特征融合为 206 维向量。随机森林在严格八折滚动前进协议下同时预测 10 日内上涨>3%和回撤>7%的概率，以 BCD-AUC 联合评估。

● 研究结论：均衡尾部检测的经济价值

ORCA 实现 BCD-AUC 0.741 排名第一，谱特征为崩盘检测贡献 +10.3pp AUC。SHAP 揭示明确分工：价格特征主导上涨检测，图拓扑特征驱动崩盘检测。集成策略实现夏普 1.13、CAGR 15.6%、最大回撤仅-7.5%，远超买入持有基准，证明分类增益具有真实经济价值。

● 文献来源

核心内容摘选自 Boris Kriuk 和 Fedor Kriuk 于 2026 年 4 月发表于 arXiv（预印本）的论文《ORCA — Online Regime Correlation Analyzer》。

● 风险提示

文献结论基于历史数据与海外文献进行总结；不构成任何投资建议。

正文目录


1	引言	4
2	相关工作	5
3	方法论	6
3.1	数据与相关性估计	6
3.2	谱特征与拓扑特征	7
3.3	传统特征	8
3.4	分类模型与滚动前进协议	8
3.5	体制判定	8
4	实验	9
4.1	实验设置	9
4.2	预测任务	9
4.3	滚动前进验证	9
4.4	分类结果	10
4.5	消融研究	10
4.6	特征重要性分析	11
5	交易策略	14
5.1	信号处理	14
5.2	二维敞口映射	14
5.3	防御性轮动	14
5.4	集成参数平均	15
5.5	绩效	15
5.6	体制行为	15
6	结论	15
	风险提示:	16

图表目录

图表 1 文章框架	4
图表 2 六个模型在两项任务上的滚动前进样本外结果	10
图表 3 不同特征配置下的样本外结果	11
图表 4 谱特征与传统特征贡献 (SHAP)	11
图表 5 SHAP 特征重要性: 上涨 vs 崩盘检测	12
图表 6 上涨 (左列) 和崩盘 (右列) 六个最具影响力特征的 SHAP 依赖图	13
图表 7 WFO 策略相对于 S&P500 买入持有基准的样本外绩效	15

1 引言

图表 1 文章框架



资料来源：华安证券研究所整理

金融危机具有一种独特的结构性特征：通常弱相关的资产开始同步运动，在主流波动率指标做出反应之前，就已压缩了跨资产相关性矩阵的特征值谱。标准风险模型（如 GARCH 族估计器和已实现方差测度）本质上是反应性的——它们在冲击已经发生后才量化价格波动的幅度。相比之下，相关性网络的谱属性在危机形成阶段就发生转变：**随着羊群行为加剧，主特征值吸收的总体方差比例不断上升，第一与第二特征值之间的谱差距收窄，相关性矩阵的有效秩坍塌——这一切都预示着分散化正在消解。**尽管这一现象已有数十年的实证支撑，但多数实务风险系统仍然将市场丰富的高维依赖结构简化为单一标量——例如 VIX 或滚动波动率估计——恰恰丢弃了可作为早期预警的拓扑信息。

本文提出 **ORCA（在线体制相关性分析器，Online Regime Correlation Analyzer）**，一个端到端框架，融合谱图理论、随机矩阵理论和监督式机器学习，在十天前瞻窗口内为上涨和崩盘事件提供校准的、持续更新的概率估计。ORCA 在一个涵盖广泛股票、行业 ETF、国际市场、固定收益、商品和货币的 24 只交易所交易工具组成的多元化资产宇宙上运行。在每个时间步，系统使用三个并行估计器构建滚动相关性矩阵——60 天窗口捕捉短期体制动态、120 天窗口反映中期结构、以及半衰期为 30 天的指数加权估计器实现自适应平滑——并从其特征分解中提取 127 个谱特征。这些特征包括多阶吸收比（ $k \in \{1, 3, 5\}$ ）、特征值熵及由此衍生的有效秩、马琴科-帕斯图尔超额量（衡量与随机矩阵零假设的距离）、作为羊群行为指标的谱差距、作为脆弱性代理的条件数、特征向量集中度指标（如第一主成分载荷的赫芬达尔指数）、图拓扑描述子（在 0.3、0.5 和 0.7 相关性阈值下计算的边密度、聚类系数和度中心化）、以及多期限动态特征（捕捉所有关键谱量在 5 天、10 天和 20 天回溯窗口下的变化率、Z 分数和加速度）。谱特征再辅以 79 个传统价格衍生指标——多期限收益率、已实现波动率和 GARCH 波动率、下行半偏差、窗口

内最大回撤、动量比、RSI、回撤深度、高阶矩（偏度、峰度）、波动率的波动率以及跨资产收益离散度——构成 206 维的联合特征向量。

统一的特征集由一个随机森林分类器摄取，该模型包含 200 棵树、最大深度为 6、采用平衡子样本类别加权，并通过 RobustScaler 进行预处理。模型在严格的滚动前进协议下评估：八个扩展窗口折叠覆盖十五年的美国市场日度数据，每个折叠包含三年训练窗口、六个月测试窗口，以及两者之间十天的间隔以防止前视污染。所有报告的指标均为纯样本外结果。ORCA 在每个时间步产生两个输出：S&P500 在十个交易日内上涨超过 3% 的概率（上涨检测，基准率≈7.7%），以及该指数在窗口内经历超过 7% 回撤的概率（崩盘检测，基准率≈0.9%）。我们通过平衡危机检测 AUC（BCD-AUC = AUC 上涨 × AUC 崩盘）联合评估两项任务，该指标惩罚仅在单方向表现优异的模型。

在滚动前进评估中，ORCA 实现了 0.741 的 BCD-AUC，在竞争性基线中排名第一。消融研究表明，谱特征族相对于仅使用传统特征，在上涨检测中贡献了+5.2% 的 AUC 增量，在崩盘检测中贡献了+10.3% 的 AUC 增量，证实了相关性网络结构编码了价格类指标所缺失的危机前兆信号。一个回测的集成滚动前进策略将上涨和崩盘排名的二维信号空间映射为连续的权益敞口——将风险偏好/风险规避轮动纳入由黄金、中期国债和美元组成的防御性组合——将这些信号转化为 1.13 的夏普比率、15.6% 的年化复合增长率（CAGR）以及仅-7.5% 的最大回撤，相比之下买入持有基准的 CAGR 为 3.7%、最大回撤为-33.7%，而该策略的平均杠杆仅为 0.39 倍。

本文的主要贡献有三个方面：

1) 谱-传统特征融合用于均衡危机检测。我们形式化了从三个并行相关性估计器中提取的 127 个特征值衍生、特征向量衍生的和图拓扑特征与 79 个经典技术指标的整合，并通过消融实验证明谱特征族为崩盘检测贡献了额外+10.3% 的 AUC、为上涨检测贡献了+5.2% 的 AUC——这些增益在最罕见且经济后果最重大的尾部事件中尤为显著。

2) 基于 BCD-AUC 指标的滚动前进评估。我们设计了具有严格十天防泄露间隔的八折时间序列交叉验证协议，并提出 BCD-AUC 作为单一汇总统计量，奖励在上涨和崩盘双方向均有效的模型，以解决危机预测文献中常见的单侧优化陷阱。ORCA 在所有评估基线中该指标排名第一。

3) 可部署的自动刷新监控系统及三维相关性网络可视化。我们将整个流水线实现为一个自包含服务器，摄取实时市场数据，每十二小时重新估计完整模型，并提供一个交互式仪表板，其中 24 资产相关性图被渲染为力导向网络，节点按特征向量中心性缩放、边按相关性着色，实现了对传统表格展示中不可见的依赖拓扑变化的实时可视化监控。

2 相关工作

金融危机的检测和预测在量化金融、计量经济学以及近年来的机器学习领域一直受到持续关注。与 ORCA 最相关的文献涵盖四个广泛领域：波动率建模与预测、金融相关性矩阵的谱分析、基于网络的系统性风险方法，以及机器学习在尾部事件预测中的应用。

基于波动率的危机检测根植于自回归条件异方差模型族，始于原始 ARCH 设定及其广义扩展 GARCH，它们将时变方差建模为过去平方收益和过去条件方差的函

数。这些模型及其众多变体——包括指数 GARCH、阈值 GARCH 和已实现 GARCH——在实务中仍是风险度量的主导范式。已实现波动率的异质自回归模型将波动率分解为日、周和月度分量，作为一种简单的线性基准已证明出人意料地有效。所有此类方法的一个共同局限在于：它们本质上是单变量且反应性的——它们在冲击到来之后才测量价格波动的幅度，而非检测先于冲击发生的结构性依赖转变。

随机矩阵理论为在大型协方差矩阵中区分真实相关结构与估计噪声提供了理论基础。马琴科-帕斯图尔分布表征了纯随机相关性矩阵的体特征值密度，使研究者能够将超过噪声阈值的特征值识别为真实经济信号的载体。**吸收比——定义为固定数量的顶部特征值所解释的总方差比例——被提出作为系统性风险的度量，其依据是吸收比上升意味着市场脆弱性增加。**实证研究记录了吸收比在重大回撤前的数月内趋于上升，其变化率可作为择时指标。ORCA 扩展了这一研究脉络，提取了更丰富的谱描述子集合，包括**特征值熵、有效秩、谱差距、条件数和特征向量集中度**，并整合了在不同时间尺度上运行的三个并行相关性估计器的特征。

基于网络的系统性风险方法将金融系统建模为一个图，节点代表资产或机构，边编码成对依赖关系——通常以相关性、偏相关或互信息度量。**最小生成树和平面最大过滤图**已被用于追踪股票市场不断演化的拓扑结构，揭示了网络结构在压力时期变得更加中心化、模块化程度降低。格兰杰因果网络和传递熵图已被用于研究跨市场和跨板块的方向性溢出效应。最近，图神经网络已被应用于金融传播建模，学习捕捉高阶关系结构的节点和边表示。**ORCA 借鉴了图拓扑特征，如在多个相关性阈值下计算的边密度、聚类系数和度中心化**，但刻意避免深度图神经架构，转而采用可解释的集成树模型——后者更适合危机预测这种小样本、非平稳的设定。

机器学习在尾部事件预测中的方法探索了梯度提升树、支持向量机、长短期记忆网络以及基于注意力的架构，用于预测市场崩盘、回撤和波动率飙升。一个反复出现的发现是：随机森林和梯度提升机等集成树方法对表格型金融数据提供了有利的偏差-方差权衡，特别是在结合谨慎的时间序列交叉验证以避免前视偏差时。类别不平衡问题——对于发生频率低于百分之一交易日的极端事件尤为严重——通常通过重采样、代价敏感学习或阈值优化来解决。ORCA 在深度受限的随机森林中采用平衡子样本类别加权，并使用无阈值指标（具体为 AUC 和平均精度）评估性能，以避免任意概率截断引入的伪影。

尽管已有大量先前工作，但尚无现有框架能够同时实现以下目标：从动态相关性网络中提取多尺度谱特征和拓扑特征、将其与传统波动率和动量指标融合、在统一平衡指标下评估上涨和崩盘检测、并将所得到的模型部署为持续刷新的监控系统且具备实时网络可视化。ORCA 旨在填补这一空白。

3 方法论

本节完整描述 ORCA 流水线：多元资产宇宙与相关性估计方案、谱特征和拓扑特征提取、传统特征基线、监督分类模型、滚动前进评估协议，以及回测策略中使用的体制-敞口映射。

3.1 数据与相关性估计

ORCA 摄取 24 只交易所交易工具的日度调整后收盘价，涵盖六大资产类别：广泛股票（S&P500、纳斯达克 100、罗素 2000）、美国行业 ETF（金融、能源、科技、医疗保健、公用事业、必需消费品、非必需消费品、工业、原材料）、国际

股票（发达国际市场、新兴市场、欧洲、日本）、固定收益（长期国债、中期国债、投资级公司债、高收益债）、商品（黄金、原油）、货币（美元）以及房地产（REITs）。价格数据通过 EODHD API 获取，并进行本地磁盘缓存，覆盖十五年的历史数据。在对不超过五个交易日的缺口进行前向填充并剔除残余缺失值后，日度简单收益率的计算公式为 $r_{i,t} = p_{i,t}/p_{i,t-1} - 1$ 。

在每个日期 t ，我们构建 $n \times n$ 跨资产相关性矩阵（其中 $n = 24$ ）的三个并行估计。第一个使用 60 天收益率的滚动窗口，第二个使用 120 天窗口，第三个使用半衰期为 30 天的指数加权协方差估计器。对于指数估计器，协方差矩阵 Σ_t^{ewm} 由指数加权二阶矩计算得到，然后通过每个元素除以对应边际标准差的乘积进行归一化，转换为相关性形式。三个矩阵均进行对称化处理，对角线设为 1，并截断至区间 $[-1, 1]$ 。使用多个窗口使模型能够区分短期体制转换（60 天）和中期结构性变化（120 天），同时受益于指数加权的自适应平滑特性。

3.2 谱特征与拓扑特征

给定相关性矩阵 $C_t \in R^{n \times n}$ ，我们计算其特征分解 $C_t = V\Lambda V^T$ ，其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ 且 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$ 。特征值和特征向量产生以下特征族。

秩 k 的吸收比衡量前 k 个特征值捕获的总方差比例：

$$AR_k = (\sum_{i=1}^k \lambda_i) / (\sum_{i=1}^n \lambda_i)$$

我们提取 AR1、AR3 和 AR5。吸收比上升表明方差正在向更少的维度集中，这是羊群行为的标志。

特征值熵量化方差在谱上的分布均匀程度：

$$H = -\sum_{i=1}^n \lambda_i \ln \lambda_i, \quad \lambda_i = \lambda_i / \sum_{j=1}^n \lambda_j$$

由熵我们推导出有效秩 $ER = \exp(H)$ ，可解释为驱动市场的独立风险因子数量。正常条件下 ER 接近 n ；危机期间它向 1 坍缩。

谱差距定义为第一与第二特征值之比 $\gamma = \lambda_1 / \lambda_2$ 。较大的差距表明单一市场因子占主导地位，与恐慌驱动的联动一致。我们还记录条件数 $\kappa = \lambda_1 / \lambda_n$ 、马琴科-帕斯图尔（Marchenko-Pastur）超额量 $\lambda_1 - (1 + \sqrt{n/T})^2$ （其中 T 为估计窗口长度）、特征值标准差、偏度和峰度。

从第一特征向量 $v_1 = (v_{1,1}, \dots, v_{1,n})^T$ 中提取集中度指标。归一化绝对载荷为 $\bar{v}_{1,i} = |v_{1,i}| / \sum_j |v_{1,j}|$ ，由此计算赫芬达尔指数 $HHI = \sum_i \bar{v}_{1,i}^2$ 、载荷熵、最大载荷以及前四分位与后四分位载荷之间的离散度。高集中度表明危机因子在资产宇宙上分布不均，而均匀载荷则表明广泛的市场压力。

对于图拓扑特征，我们在 $\tau \in \{0.3, 0.5, 0.7\}$ 三个水平上对绝对相关性矩阵进行阈值化，得到二元邻接矩阵 $A^{(\tau)}_{ij} = 1[|C_{t,ij}| > \tau]$ ，对角线为零。在每个阈值下，我们计算边密度、平均度、度标准差、最大度、孤立节点数、弗里曼度中心化以及全局聚类系数：

$$C^{(\tau)} = \left[\sum_i \sum_{j < k} A^{(\tau)}_{ij} A^{(\tau)}_{jk} A^{(\tau)}_{ik} \right] / \left[\sum_i \left(d_i^{(\tau)} \text{choose } 2 \right) \right]$$

其中 $d_i^{(\tau)} = \sum_j A^{(\tau)}_{ij}$ 为节点 i 的度。我们额外记录汇总相关性统计量：均值、中位数和最大绝对相关性、相关性标准差和偏度，以及超过 0.50 和 0.70 的相关对的占比。

为捕捉体制转换的动态特征，我们对八个关键谱量——主特征值、其方差份额、一阶吸收比、特征值熵、有效秩、平均绝对相关性、0.50 阈值下的边密度以及 0.50 阈值下的聚类系数——在 5 天、10 天和 20 个交易日的期限内计算一组时间导数：百分比变化率、绝对差值，以及以两倍期限长度的窗口计算的滚动 z 分数。我们还记录每个量的加速度（二阶差分）和 252 天滚动百分位排名。这一思路产生了一个动态特征集，不仅追踪谱体制变化的水平，还追踪其速度和加速度。

所有谱特征、特征向量特征、拓扑特征和动态特征均从三个相关性估计器中分别提取，共计产生 127 个特征。

3.3 传统特征

为提供有竞争力的基线并为模型补充相关性谱中缺失的价格水平信息，我们从 S&P500 价格序列和多元资产收益面板中构建 79 个传统特征。这些特征包括：1 天、5 天、10 天、20 天和 60 天的多期限收益率；5 天、10 天、20 天和 60 天的滚动年化波动率；波动率比率（5 日对 20 日、10 日对 60 日）；参数为 $\alpha = 0.1$ 、 $\beta = 0.85$ 的 GARCH(1,1) 条件波动率估计；20 天下行半偏差；5 天和 20 天窗口内的最大单日损失；10 日、20 日和 50 日的价格与移动平均之比；14 日 RSI；相对 20 日和 60 日滚动高点的回撤；20 日和 60 日滚动偏度与峰度；波动率的波动率（5 日滚动波动率的 20 日标准差）；以及跨资产收益离散度——定义为全部 24 只工具日度收益率的横截面标准差。127 个谱特征与 79 个传统特征拼接为 206 维的联合向量。

3.4 分类模型与滚动前进协议

联合特征向量经稳健缩放器预处理（以中位数为中心、以四分位距为缩放），任何残余的非有限值替换为零。缩放后的特征输入随机森林分类器，包含 200 棵树、最大深度为 6、每叶节点最少 30 个样本、每次分裂最少 60 个样本，并采用平衡子样本类别加权以应对稀有事件预测中固有的严重类别不平衡。

我们在 S&P500 上定义两个十天前瞻窗口的二元预测目标。上涨目标在终点收益超过 3% 时等于 1。崩盘目标在从入场价格起的窗口内最大回撤超过 7% 时等于 1。基准率分别约为 7.7% 和 0.9%。

评估遵循严格的滚动前进协议，包含八个扩展窗口折叠。每个折叠使用三年训练窗口、十天间隔以防止重叠收益期限的信息泄露，以及六个月的样本外测试窗口。各折叠按顺序排列，测试期之间无重叠。本文报告的所有指标均在跨折叠汇总的样本外预测上计算。

我们使用无阈值指标评估两项任务，以避免任意概率截断引入的伪影：AUC-ROC 和平均精度。对于精确率、召回率和 F1，我们在样本外预测上选择使 F1 最大化的概率阈值，并截断至区间 [0.05, 0.95]。为获得一个奖励在双方向均有效模型的单一汇总统计量，我们定义平衡危机检测 AUC：

$$BCD - AUC = \sqrt{AUC_{\text{上涨}} \times AUC_{\text{崩盘}}}$$

几何均值比算术均值更严厉地惩罚仅在单方向表现优异的模型，这是合意的——因为一个能检测上涨但错过崩盘（或反之）的系统在实际中价值有限。

3.5 体制判定

模型产生的原始上涨概率和崩盘概率分别转换为 126 天滚动百分位排名 $\hat{r}_t$ 和 $\hat{c}_t$ ，以使阈值在不同市场体制间保持平稳。一个确定性规则将二维信号 $(\hat{r}_t, \hat{c}_t)$ 映射到五种体制之一：**正常、上涨、谨慎、亢奋和危机**。同一信号对通过一个基于条件收益分析校准的分段函数映射为连续的权益敞口乘数 $w_t \in [0, 1.5]$ 。当 $\hat{r}_t \geq 0.90$ 或 $\hat{c}_t \geq 0.60$ 时，敞口设为零——前者对应上涨过度自信（历史上通常先于负收益出现），后者对应崩盘风险升高。当 $0.78 \leq \hat{r}_t < 0.90$ 且 $\hat{c}_t < 0.40$ 时，敞口达到最大值 1.5 倍。中间区间根据崩盘排名获得 0.3、0.7、1.0 或 1.2 的敞口。

4 实验

4.1 实验设置

我们在 15 年的美国市场日度数据（2009–2024）上评估 ORCA，覆盖六大类别的 24 只多元化资产：广泛股票（SPY、QQQ、IWM）、行业 ETF（XLF、XLE、XLK、XLV、XLU、XLP、XLY、XLI、XLB、XLRE）、国际市场（EFA、EEM、VGK、EWJ）、固定收益（TLT、IEF、LQD、HYG）、商品（GLD、USO）以及货币（UUP）。该资产宇宙刻意保持异构性：谱特征的预测能力来源于跨资产相关性动态，多元化的宇宙确保相关性矩阵捕捉的是真实的结构性转变而非特定行业的噪声。

所有数据来自 EODHD API，使用调整后收盘价。收益率以日度百分比变化计算。缺失值前向填充最多五天；残余缺口予以剔除。最终对齐后的数据集包含全部 24 只资产约 3,750 个交易日。

4.2 预测任务

我们定义两个互补的二元分类任务，旨在捕捉双方向的极端尾部事件：

上涨检测。 目标为 1，如果 S&P500 在未来 10 个交易日内的终点收益超过 3%，即 $r_{t+10} = P_{t+10}/P_t - 1 > 0.03$ 。基准率约为 7.7%，属于中等不平衡问题。

崩盘检测。 目标为 1，如果 S&P500 在未来 10 个交易日内的最大窗口内回撤超过 7%，即 $\min_{k \in [1, 10]} P_{t+k}/P_t - 1 < -0.07$ 。基准率约为 0.9%，属于严重不平衡的稀有事件检测问题。回撤形式的设计有意比终点收益指标更为保守：它捕捉的是窗口期内的阶段性压力，而期末快照可能遗漏这种压力。

两项任务通过平衡危机检测 AUC（BCD-AUC）联合评估，定义为各任务 AUC-ROC 分数的几何均值： $BCD-AUC = \sqrt{AUC_{\text{上涨}} \times AUC_{\text{崩盘}}}$ ，该指标惩罚在一个方向表现优异而以牺牲另一个方向为代价的模型，奖励均衡的检测能力。

4.3 滚动前进验证

时间序列数据不适用标准交叉验证。我们采用严格的滚动前进协议，具备防泄露保证：

1. 训练窗口：3 年。
2. 间隔：训练结束与测试开始之间设 10 个交易日间隔，防止 10 天预测窗口产生的任何目标泄露。
3. 测试窗口：6 个月。

4. 折叠：8 个不重叠的测试期。

所有报告的指标均在样本外测试折叠上计算。不对测试数据进行超参数调优；随机森林配置（200 棵树、最大深度 6、每叶节点最少 30 个样本、平衡子样本类别加权）在所有折叠和任务中保持固定。

4.4 分类结果

图表 2 展示了全部六个模型在两项任务上的滚动前进样本外结果。

ORCA 实现了最高的 BCD-AUC 0.741，总排名第一。有若干模式值得讨论。

第一，ORCA 在上涨 AUC (0.772) 上以显著优势领先所有基线，最接近的竞争者传统 RF 为 0.736。这一观察表明，**谱特征与传统特征的组合捕捉到了任一特征集单独无法实现的上行动量信号**。

第二，HAR-RV 在崩盘 AUC 上取得最高值 (0.763)，在该单项任务上超过 ORCA 的 0.711。然而 HAR-RV 的上涨 AUC 仅为 0.696，显著偏弱，导致 BCD-AUC 较低为 0.729。这一模式说明了几何均值指标的价值：HAR-RV 的崩盘检测优势以牺牲上涨检测为代价，而 ORCA 在两个方向均保持高性能。

第三，Turbulence 基线在两项任务上均表现不佳 (BCD-AUC 0.605)，尽管它是一个被广泛引用的危机指标。这与如下理解一致：马氏距离是一个同步而非先行指标——它在危机期间而非危机之前达到峰值。

图表 2 六个模型在两项任务上的滚动前进样本外结果

Model	Rally	Crash	BCD-AUC	#Feat
ORCA (Ours)	0.772	0.711	0.741	206
HAR-RV	0.696	0.763	0.729	4
SMA Volatility	0.682	0.671	0.676	9
Traditional RF	0.736	0.608	0.669	27
Spectral Only RF	0.620	0.666	0.643	179
Turbulence	0.647	0.565	0.605	5

资料来源：《ORCA — Online Regime Correlation Analyzer》，华安证券研究所

4.5 消融研究

图表 3 通过在相同的模型和滚动前进验证设置下比较三种特征配置，隔离了谱特征的贡献。

谱特征的贡献是不对称的。对于崩盘检测，在传统特征基础上添加谱特征带来了+10.3 个百分点的 AUC 提升 (0.608 → 0.711)，这是我们实验中最大的单一来源增益。仅谱特征在该任务上就已超过传统特征 (0.666 vs. 0.608)，证实了核心假设：**相关性网络结构编码了单变量价格特征所缺失的危机前兆信号**。

对于上涨检测，谱特征单独表现不如传统特征 (0.620 vs. 0.736)，但二者组合取得了最佳分数 (0.772, +3.6 个百分点的提升)。这种互补性表明谱特征提供的是正交的体制级上下文信息，而非对动量或波动率信号的重复。


图表 3 不同特征配置下的样本外结果

Feature Set	Rally AUC	Crash AUC	Δ vs Trad.
Traditional only	0.736	0.608	baseline
Spectral only	0.620	0.666	-0.116/+0.058
Combined (ORCA)	0.772	0.711	+0.036/+0.103

资料来源：《ORCA — Online Regime Correlation Analyzer》，华安证券研究所

图表 4 通过汇总的 SHAP 重要性量化了这种不对称性。在绝对量上，崩盘模型的总 SHAP 质量由谱/图特征主导（0.376 vs. 0.151），对应 71.3% 的相对占比——几乎是传统特征贡献的三倍。上涨模型则更为均衡（谱特征 46.9%，传统特征 53.1%），与消融表一致：传统动量和回撤特征承载上涨信号，而谱特征在边际上进行精炼。

图表 4 谱特征与传统特征贡献（SHAP）




资料来源：《ORCA — Online Regime Correlation Analyzer》，华安证券研究所

4.6 特征重要性分析

我们通过 SHAP 检查个体特征重要性及其非线性依赖关系，计算基于全部八个滚动前进折叠的汇总样本外预测。图表 5 按平均绝对 SHAP 值对每个任务的前 20 个特征进行排名。对于上涨检测，最重要的四个特征——drawdown(60d)、price_to_sma_50、max_loss_5d 和 drawdown_20d——全部为价格类特征，捕捉的是压力后的均值回归。谱特征在排名中位置较低，起到的是精炼而非主导信号的作用。对于崩盘检测，图景发生反转：排名前三的特征——clustering_coef_t50_pct_252d、edge_density_t50_pct_252d 和 lambda_1_ratio_pct_252d——全部为图拓扑特征，追踪的是资产宇宙相对于近期历史变得多紧密相关。传统特征如 price_to_sma_50 和 volatility_20d 仍然相关，但居于次要排名。

图表 5 SHAP 特征重要性：上涨 vs 崩盘检测



资料来源：《ORCA — Online Regime Correlation Analyzer》，华安证券研究所

图表 6 并排展示了上涨（左列）和崩盘（右列）六个最具影响力特征的 SHAP 依赖图。每个点为一个样本外观测；颜色从蓝色（低特征值）到红色（高特征值）渐变。

回撤(60d)。对于上涨，关系呈曲棍球棒状：当回撤较浅时 SHAP 接近零，但当回撤加深超过约 -4σ 时急剧转正，捕捉的是压力后的均值回归。对于崩盘，依赖关系反转：较深的先前回撤产生负的 SHAP，反映了严重崩盘很少在无反弹的情况下连续发生的经验规律。

价格与 50 日均线之比。价格远低于 50 日均线时产生正的上涨 SHAP（均值回归）和轻微正的崩盘 SHAP（进一步恶化的风险）。价格远高于均线时抑制上涨 SHAP，与过度延伸一致。

5 日最大损失。极端的近期损失产生强烈负的上漲 SHAP——剧烈压力抑制即时反弹预测——但对崩盘 SHAP 影响较弱，表明崩盘模型更多依赖结构性（谱）而非急性（价格）压力信号。


20 日波动率。两项任务均呈现双体制结构。在低波动率下 SHAP 广泛分散（信息量低）。在高波动率（ $>4\sigma$ ）下，两个模型均赋予正 SHAP：波动率飙升信号预示尾部事件，但方向由其他特征判定。

聚类系数。这是最显著的依赖关系。对于崩盘检测出现一个陡峭悬崖：当 252 天百分位降至约 -0.4 以下（相关性网络变得异常稀疏）时，SHAP 骤降至 -0.06 至 -0.08 ，强烈推向崩盘类别。聚类的突然坍塌信号着先前关联资产之间的去相关——

——这是流动性撤回和避险转移在市场错位之前的标志。对于上涨检测，同一特征在其取值范围内 SHAP 接近零，证实了其崩盘特异性的信息含量。

20 日回撤。与 60 日版本类似但记忆更短。较深的 20 日回撤产生正的上涨 SHAP，但对崩盘检测的效果相对于谱特征有所减弱，强化了如下层级关系：网络拓扑在预测系统性事件方面比短期回撤更为重要。

图表 6 上涨（左列）和崩盘（右列）六个最具影响力特征的 SHAP 依赖图



资料来源：《ORCA — Online Regime Correlation Analyzer》，华安证券研究所

综合来看，SHAP 分析为消融结果提供了机理性解释：传统回撤和动量特征主

导上涨检测，因为上涨是由价格驱动的均值回归事件。相比之下，崩盘之前会出现相关性网络的结构转变——由聚类系数、边密度和特征值比率捕捉——这些变化对单变量价格统计不可见。ORCA 之所以成功，是因为它融合了两个信号家族，在两个方向上重建了均衡的尾部事件检测能力。

5 交易策略

为评估 ORCA 的分类信号是否能转化为具有经济意义的组合决策，我们设计了一个回测交易策略——集成滚动前进优化——将上涨和崩盘概率估计转化为动态权益敞口。该策略实现了 1.13 的夏普比率、15.6% 的年化复合增长率（CAGR）以及仅-7.5% 的最大回撤，而同期 S&P500 买入持有基准的夏普比率为 0.09、最大回撤为-33.7%。

5.1 信号处理

模型的原始输出 $\hat{p}_t^{rally}$ 和 $\hat{p}_t^{crash}$ 是非平稳的：其分布特性随滚动前进折叠中市场体制的演化而漂移。为对这些信号进行归一化，我们施加 126 天（6 个月）滚动百分位排名变换：

$$R_t = \text{rank}(\hat{p}_t \text{ within } \hat{p}_{t-125}, \dots, \hat{p}_t) / 126$$

得到上涨排名 $R_t^r \in [0,1]$ 和崩盘排名 $R_t^c \in [0,1]$ 。该变换严格因果——仅使用过去和当前的预测——并适应局部信号分布，无需任何前瞻性校准。

5.2 二维敞口映射

我们并非独立处理上涨和崩盘信号，而是基于在内部训练期间计算的各百分位区间的条件收益分析，定义联合敞口函数 $w_t = f(R_t^r, R_t^c) \in [0,1.5]$ 。关键实证发现有三方面。**第一**，上涨排名高于第 90 百分位对应约-189% 的年化条件收益，是数据集中最强的单一卖出信号；这一反直觉的结果反映了极端模型置信度与市场过度延伸同时出现的倾向。**第二**，崩盘排名高于第 60 百分位对应年化条件收益在-17% 至-25% 之间。**第三**，上涨排名在第 78 至 90 百分位区间且崩盘排名同时较低时产生最高的正条件收益，代表一个高确信度体制。

敞口映射的分配规则为：当上涨排名超过 0.90（亢奋退出）或崩盘排名超过 0.60（危险退出）时，权益配置为零；当上涨排名处于甜蜜区间（0.78–0.90）且崩盘排名低于 0.40 时，配置最大值 1.5 倍；其他组合根据联合信号状态获得 1.2 倍、1.0 倍、0.7 倍或 0.3 倍的中间配置。敞口决策至少持有 8 个交易日。

5.3 防御性轮动

当权益敞口降至 1.0 倍以下时，释放的资本并非以零收益现金持有，而是轮动至一个防御性组合，comprising 50% 黄金（GLD）、30% 中期国债（IEF）和 20% 美元指数（UUP）。选择这些资产是因为它们在权益压力事件中通过避险转移动态具有经验性的升值倾向。在评估期内，该防御性组合实现了正 CAGR、低波动率，且在回撤期间与权益呈负相关。这种风险偏好/风险规避（RORO）机制将原本的闲置资本转化为正收益配置，相较于防御时持有现金的替代方案，实质性提升了策略的夏普比率。

5.4 集成参数平均

为缓解对任何单一参数配置的过拟合，我们在信号历史的前 55%（内部训练期）上对敞口映射阈值进行网格搜索。网格涵盖上涨进入和退出阈值、崩盘进入和退出阈值、基准敞口水平、持有期、反弹配置和杠杆限制，共计约 50,000 种参数组合。每组合以考虑交易成本（每单位仓位变动 5 个基点）和杠杆成本（超过 1.0 倍敞口部分年化 50 个基点）后的样本内夏普比率进行评估。

我们不选择单一最优参数集——那将最大化样本内夏普比率但通过过拟合导致样本外退化——而是对排名前 20 的参数集生成的仓位进行平均。集成平均平滑了特异性参数敏感性，减少了单最优选择所特有的从训练到测试的夏普比率退化。集成方法的动机在于：多个高性能参数集在大方向信号上达成一致（在亢奋和崩盘危险时退出，在上涨甜蜜区间时进入），但在精确阈值位置上存在分歧，因此平均保留了共识信号同时剔除了噪声。

5.5 绩效

图表 7 报告了集成 WFO 策略相对于 S&P500 买入持有基准的样本外绩效。

集成 WFO 策略实现了 1.13 的夏普比率、15.6% 的 CAGR 以及仅 -7.5% 的最大回撤，Calmar 比率为 2.09。基准的夏普比率为 0.09、CAGR 为 3.7%、最大回撤为 -33.7%（Calmar 0.11）。因此，该策略将风险调整后收益提高了 12 倍以上，同时将最严重的峰谷损失降低了约 4.5 倍。

Calmar 比率 2.09 值得特别强调。它表明该策略的年化收益超过其最大回撤的两倍。对于一个跨越 10 年样本外窗口（包含 2020 年 COVID 崩盘和 2022 年加息回撤）的系统化策略而言，这种回撤控制水平是崩盘检测信号前置时间的直接结果。

图表 7 WFO 策略相对于 S&P500 买入持有基准的样本外绩效

Strategy	Sharpe	CAGR	Max DD	Calmar
Ensemble WFO (Ours)	1.13	15.6%	-7.5%	2.09
Buy & Hold (Benchmark)	0.09	3.7%	-33.7%	0.11

资料来源：《ORCA — Online Regime Correlation Analyzer》，华安证券研究所

5.6 体制行为

按敞口体制分解收益揭示了策略绩效背后的机制。在高权益时期（敞口 ≥ 0.8 倍），策略以超过基准的平均年化收益捕捉权益上行。在防御时期（敞口 ≤ 0.01 倍），RORO 组合在权益市场下跌期间通过黄金和国债升值产生小额正收益。策略在事前区分体制的能力——在上涨和崩盘信号均有利时激进配置，在任一信号指示危险时防御性轮动——是 alpha 的主要来源。

6 结论

本文提出了 ORCA，一个端到端框架，融合从动态跨资产相关性网络中提取的谱特征和拓扑特征与传统价格类指标，在十天前瞻窗口内为上涨和崩盘事件产生校

准的、持续更新的概率估计。通过在不同时间尺度上构建三个并行相关性估计器，并将其分解为 127 个谱特征、特征向量特征和图拓扑特征，ORCA 捕捉了尾部事件前兆的结构性依赖转变——这些信息对常规单变量波动率测度不可见。

在跨越十五年美国市场日度数据、具有十天防泄露间隔的严格八折滚动前进评估中，ORCA 实现了 0.741 的平衡危机检测 AUC，在所有基线（包括 HAR-RV、动荡指数和仅传统特征随机森林）中排名第一。消融研究隔离出谱特征贡献为崩盘检测+10.3 个百分点 AUC、上涨检测+5.2 个百分点，证实了核心假设：相关性网络结构编码了价格类指标所缺失的危机前兆信号。SHAP 分析揭示了明确的分工：传统回撤和动量特征作为均值回归信号主导上涨检测，而图拓扑描述子——聚类系数、边密度和特征值比率——通过捕捉系统性压力前分散化的坍塌来驱动崩盘检测。回测的集成滚动前进策略将这些信号转化为 1.13 的夏普比率和仅-7.5%的最大回撤（买入持有为-33.7%），证明分类增益具有真实的经济价值。

应承认若干局限性。模型仅在美国股票市场评估；谱特征是否在其他地理区域或资产类别中保持预测能力有待检验。随机森林架构虽然可解释且在所选深度下对过拟合具有稳健性，但相较于梯度提升或深度学习替代方案可能 exploited 高阶特征交互，存在性能提升空间。回测策略尽管采用了集成平均和交易成本建模，但本质上受到历史模拟的注意事项约束：执行滑点、流动性约束以及样本中未呈现的体制变化可能侵蚀实盘表现。

未来工作将沿若干方向推进：扩展资产宇宙以纳入国际市场和另类资产类别，检验谱危机前兆的普适性；以在线或增量训练模型替换静态随机森林，适应非平稳特征分布；引入更高频的日内相关性动态以提升信号时效性；以及进行实盘模拟交易验证以衡量回测与实际表现之间的差距。总体而言，ORCA 证明跨资产相关性网络的谱属性构成了均衡尾部事件检测中一个丰富且尚未充分利用的预测信息源，而将这一结构性信号与经典技术指标融合，可在危机预判和组合风险管理两方面产生具有经济显著性的改善。

文献来源：

核心内容摘选自 Boris Kriuk 和 Fedor Kriuk 于 2026 年 4 月发表于 arXiv（预印本）的论文《ORCA — Online Regime Correlation Analyzer》。

风险提示：

文献结论基于历史数据与海外文献进行总结；不构成任何投资建议。

重要声明

分析师声明

本报告署名分析师具有中国证券业协会授予的证券投资咨询执业资格，以勤勉的执业态度、专业审慎的研究方法，使用合法合规的信息，独立、客观地出具本报告，本报告所采用的数据和信息均来自市场公开信息，本人对这些信息的准确性或完整性不做任何保证，也不保证所包含的信息和建议不会发生任何变更。报告中的信息和意见仅供参考。本人过去不曾与、现在不与、未来也将不会因本报告中的具体推荐意见或观点而直接或间接接收任何形式的补偿，分析结论不受任何第三方的授意或影响，特此声明。

免责声明

华安证券股份有限公司经中国证券监督管理委员会批准，已具备证券投资咨询业务资格。本报告中的信息均来源于合规渠道，华安证券研究所力求准确、可靠，但对这些信息的准确性及完整性均不做任何保证。在任何情况下，本报告中的信息或表述的意见均不构成对任何人的投资建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。华安证券及其所属关联机构可能会持有报告中提到的公司所发行的证券并进行交易，还可能为这些公司提供投资银行服务或其他服务。

本报告仅向特定客户传送，未经华安证券研究所书面授权，本研究报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。如欲引用或转载本文内容，务必联络华安证券研究所并获得许可，并需注明出处为华安证券研究所，且不得对本文进行有悖原意的引用和删改。如未经本公司授权，私自转载或者转发本报告，所引起的一切后果及法律责任由私自转载或转发者承担。本公司并保留追究其法律责任的权利。

投资评级说明

以本报告发布之日起 6 个月内，证券（或行业指数）相对于同期相关证券市场代表性指数的涨跌幅作为基准，A 股以沪深 300 指数为基准；新三板市场以三板成指（针对协议转让标的）或三板做市指数（针对做市转让标的）为基准；香港市场以恒生指数为基准；美国市场以纳斯达克指数或标普 500 指数为基准。定义如下：

行业评级体系

- 增持—未来 6 个月的投资收益率领先市场基准指数 5%以上；
- 中性—未来 6 个月的投资收益率与市场基准指数的变动幅度相差-5%至 5%；
- 减持—未来 6 个月的投资收益率落后市场基准指数 5%以上；

公司评级体系

- 买入—未来 6-12 个月的投资收益率领先市场基准指数 15%以上；
- 增持—未来 6-12 个月的投资收益率领先市场基准指数 5%至 15%；
- 中性—未来 6-12 个月的投资收益率与市场基准指数的变动幅度相差-5%至 5%；
- 减持—未来 6-12 个月的投资收益率落后市场基准指数 5%至 15%；
- 卖出—未来 6-12 个月的投资收益率落后市场基准指数 15%以上；
- 无评级—因无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使无法给出明确的投资评级。